

# 柳志轩

上海 | lzx993124494@sjtu.edu.cn | GitHub | Scholar | OpenReview

研究方向：大语言模型训练与推理，重点关注安全蒸馏、推理时对齐、高效解码与搜索式生成

## 教育经历

### 上海交通大学

计算机科学与技术，博士研究生；电子信息与电气工程学院

2022.09–2027.06 (预计)

上海

### 上海交通大学

计算机科学与技术，工学学士；ACM 班，致远学院

2018.09–2022.06

上海

## 研究经历

### 上海人工智能实验室

大语言模型安全蒸馏、推理时对齐与高效解码

研究实习生，2022–至今

#### Subliminal Learning as Trait-Direction Drift: A Mechanism and Targeted Control under SFT Distillation

第一作者；进行中的工作

- 独立负责选题、方法、实现、实验与论文写作；提出 trait-direction drift 机制，解释隐藏特质如何通过语义无关的蒸馏数据迁移至学生模型。
- 提出 probe-space corridor 定向抑制特质漂移，将 malicious-response transfer 从 29.55% 降至 6.47%，同时保持主任务性能。

#### Decoupled Contrastive Decoding via Expert-Aligned Drafting (DCD)

第一作者；进行中的工作

- 独立负责选题、方法、SGLang 实现、实验与论文写作；提出 DCD，以 expert-aligned drafter 替代串行 amateur proposal，并保持原始 contrastive decoding 的目标分布。
- 在 HumanEval、GSM8K、MMLU 与 CNN/DM 的三组 8B 配置上获得 1.65–1.95 $\times$  平均加速，70B 扩展达到约 2 $\times$  加速。

#### Inference-Time Language Model Alignment via Integrated Value Guidance (IVG)

共同第一作者 (第一署名)；  
EMNLP 2024 Findings

- 负责选题、方法、代码、实验与论文写作；提出 IVG，结合 token-level 隐式价值与 chunk-level 搜索，在无需微调目标大模型的情况下对齐生成。
- 在 AlpacaEval 2.0 上将 Mistral-7B / Mixtral-8 $\times$ 7B 的 LC win rate 从 19.51% / 25.58% 提升至 26.51% / 33.75%；后续扩展为 SafeWork-R1 的推理时对齐模块，将安全得分从 77.1 提升至 93.8。[代码]

#### Weak-to-Strong Search: Align Large Language Models via Searching over Small Language Models

第二作者 / Core Contributor；  
NeurIPS 2024

- 深度参与构思、方法、代码、实验与论文写作；以小模型偏好差构造 dense reward/value，通过 Chunk-level Beam Search 引导冻结大模型，支持跨词表与黑盒模型。
- 使用 LC win rate 约 9.5% 的 7B 弱模型，将 Llama-3-70B-Instruct 从 34.42% 提升至 39.09%；对黑盒 GPT-3.5-Turbo-Instruct 从 16.00% 提升至 20.07%。[代码]

### 字节跳动 AI Lab

神经符号学习、程序合成与数值推理

研究实习生，2020.09–2021.06

#### A Neural-Symbolic Approach to Natural Language Understanding

第一作者；EMNLP 2022 Findings

- 负责选题、方法、实现、数据、实验与论文写作；提出 Neural-Symbolic Processor，以 Mixture-of-Experts 结合神经预测与程序生成 / 符号执行。
- 构建 32,011 条 DROP 程序监督数据和 722 条 AWPNLI E/C-Program 标注；在 DROP 上达到 80.81 EM / 84.01 F1，复杂乘除与平均运算 F1 相对 neural baseline 提升 56.42，AWPNLI accuracy 达 92.24%。[代码]

## 其他代表性论文

Native Reasoning Models: Training Language Models to Reason on Unverifiable Data ICLR 2026 Poster；第二作者

Adaptive Prompt Optimization for Open-Ended Tasks: Uncertainty Preference as a Secondary Signal ACL 2026 Findings；第二作者

Emergent Response Planning in LLMs ICML 2025 Poster；第三作者

## 技能与荣誉

编程与框架：Python, PyTorch, Hugging Face Transformers, SGLang 语言：英语 CET-6

核心技术：模型蒸馏与 SFT, DPO, reward/value modeling, speculative/contrastive decoding, 搜索式生成

荣誉：全国青少年信息学奥林匹克竞赛 (NOI) 银牌，2017