

柳志轩

✉ lzx993124494@sjtu.edu.cn · 上海

🌐 chadlzx · 🏠 个人主页 · Google Scholar · OpenReview

教育经历

- 上海交通大学，计算机科学与技术博士 2022–2027
电子信息与电气工程学院；导师：乔宇；预计 2027 年 6 月毕业
- 上海交通大学，计算机科学与技术学士（ACM 班，致远学院） 2018–2022

研究经历

- 上海人工智能实验室，研究实习生 2022–至今
Subliminal Learning as Trait-Direction Drift 第一作者 · 进行中的工作

- 提出特质方向漂移机制与探针空间走廊正则化方法，将隐式偏好转移场景下的恶意响应迁移率从 **29.55%** 降至 **6.47%**，同时保持主任务性能。

- Decoupled Contrastive Decoding via Expert-Aligned Drafting* 一作 · arXiv 2026

- 以专家对齐的草稿模型替代串行弱模型提议阶段，在保持精确对比解码的同时于 8B 获得 **1.65–1.95×** 加速，70B 达到约 **2×**。

- Inference-Time Alignment via Integrated Value Guidance (IVG)* 一作 · EMNLP 2024 Findings

- 结合词元级隐式价值引导与分块级搜索，将 AlpacaEval 2.0 的长度控制胜率从 **19.51%/25.58%** 提升至 **26.51%/33.75%**。

- Weak-to-Strong Search* 二作 · 核心贡献者 · NeurIPS 2024

- 以小模型偏好引导分块级搜索，将 Llama-3-70B 从 **34.42%** 提升至 **39.09%**，并将黑盒 GPT-3.5 从 **16.00%** 提升至 **20.07%**。

- 字节跳动 AI Lab，研究实习生 2020.09–2021.06

- A Neural-Symbolic Approach to Natural Language Understanding* 一作 · EMNLP 2022 Findings

- 提出神经符号处理器，构建 **32,011** 条 DROP 与 **722** 条 AWPNI 程序标注，在 DROP 上达到 **84.01 F1**，在 AWPNI 上达到 **92.24%** 准确率。

其他论文

- Native Reasoning Models: Training Language Models to Reason on Unverifiable Data*, ICLR 2026 海报论文，二作。
- Adaptive Prompt Optimization for Open-Ended Tasks: Uncertainty Preference as a Secondary Signal*, ACL 2026 Findings, 二作。
- Scaling Model-Generated Distillation Data Can Make Latent Teacher Traits More Recoverable*, 二作，进行中的工作。
- Emergent Response Planning in LLMs*, ICML 2025, 三作。
- SafeWork-R1: Coevolving Safety and Intelligence under the AI-45° Law*, 原则价值模型引导模块贡献者。

技能与荣誉

- Python, PyTorch, HuggingFace Transformers, SGLang, SFT/DPO, reward/value modeling, speculative decoding, contrastive decoding, search-based generation.
- 全国青少年信息学奥林匹克竞赛 (NOI) 银牌, 2017。