

柳志轩

上海 | lzx993124494@sjtu.edu.cn | GitHub | Scholar | OpenReview

研究方向：大语言模型训练与推理，重点关注安全蒸馏、推理时对齐、高效解码与搜索式生成

教育经历

上海交通大学	2022.09–2027.06 (预计)
计算机科学与技术，博士研究生；电子信息与电气工程学院	上海
上海交通大学	2018.09–2022.06
计算机科学与技术，工学学士；ACM 班，致远学院	上海

研究经历

上海人工智能实验室	研究实习生，2022–至今
大语言模型安全蒸馏、推理时对齐与高效解码	

Subliminal Learning as Trait-Direction Drift: A Mechanism and Targeted Control under SFT Distillation 第一作者；进行中的工作

- 独立负责选题、方法、实现、实验与论文写作；提出 trait-direction drift 机制，解释隐藏特质如何通过语义无关的蒸馏数据迁移至学生模型。
- 提出 probe-space corridor 定向抑制特质漂移，将 malicious-response transfer 从 **29.55%** 降至 **6.47%**，同时保持主任务性能。

Decoupled Contrastive Decoding via Expert-Aligned Drafting (DCD) 第一作者；arXiv 预印本，2026

- 独立负责选题、方法、SGLang 实现、实验与论文写作；提出 DCD，以 expert-aligned drafter 替代串行 amateur proposal，并保持原始 contrastive decoding 的目标分布。
- 在 HumanEval、GSM8K、MMLU 与 CNN/DM 的三组 8B 配置上获得 **1.65–1.95×** 平均加速，70B 扩展达到约 **2×** 加速。[代码]

Inference-Time Language Model Alignment via Integrated Value Guidance (IVG) 共同第一作者（第一署名）；EMNLP 2024 Findings

- 负责选题、方法、代码、实验与论文写作；提出 IVG，结合 token-level 隐式价值与 chunk-level 搜索，在无需微调目标大模型的情况下对齐生成。
- 在 AlpacaEval 2.0 上将 Mistral-7B / Mixtral-8×7B 的 LC win rate 从 **19.51%** / **25.58%** 提升至 **26.51%** / **33.75%**；后续扩展为 SafeWork-R1 的推理时对齐模块，将安全得分从 **77.1** 提升至 **93.8**。[代码]

Weak-to-Strong Search: Align Large Language Models via Searching over Small Language Models 第二作者 / Core Contributor；NeurIPS 2024

- 深度参与构思、方法、代码、实验与论文写作；以小模型偏好差构造 dense reward/value，通过 Chunk-level Beam Search 引导冻结大模型，支持跨词表与黑盒模型。
- 使用 LC win rate 约 **9.5%** 的 7B 弱模型，将 Llama-3-70B-Instruct 从 **34.42%** 提升至 **39.09%**；对黑盒 GPT-3.5-Turbo-Instruct 从 **16.00%** 提升至 **20.07%**。[代码]

字节跳动 AI Lab 研究实习生，2020.09–2021.06

A Neural-Symbolic Approach to Natural Language Understanding 第一作者；EMNLP 2022 Findings

- 负责选题、方法、实现、数据、实验与论文写作；提出 Neural-Symbolic Processor，以 Mixture-of-Experts 结合神经预测与程序生成 / 符号执行。
- 构建 **32,011** 条 DROP 程序监督数据和 **722** 条 AWPNNLI E/C-Program 标注；在 DROP 上达到 **80.81 EM** / **84.01 F1**，复杂乘除与平均运算 F1 相对 neural baseline 提升 **56.42**，AWPNNLI accuracy 达 **92.24%**。[代码]

其他代表性论文

Native Reasoning Models: Training Language Models to Reason on Unverifiable Data	ICLR 2026 Poster；第二作者
Adaptive Prompt Optimization for Open-Ended Tasks: Uncertainty Preference as a Secondary Signal	ACL 2026 Findings；第二作者
Emergent Response Planning in LLMs	ICML 2025 Poster；第三作者

技能与荣誉

编程与框架：Python, PyTorch, Hugging Face Transformers, SGLang **语言：**英语 CET-6
核心技术：模型蒸馏与 SFT, DPO, reward/value modeling, speculative/contrastive decoding, 搜索式生成
荣誉：全国青少年信息学奥林匹克竞赛 (NOI) 银牌，2017