

柳志轩

上海 | lzx993124494@sjtu.edu.cn | GitHub | Scholar | OpenReview

研究方向: 大语言模型训练与推理, 重点关注安全蒸馏、推理时对齐、高效解码与搜索式生成

教育经历

上海交通大学	2022.09–2027.06 (预计)
计算机科学与技术, 博士研究生; 电子信息与电气工程学院	上海
上海交通大学	2018.09–2022.06
计算机科学与技术, 工学学士; 致远学院	上海

研究经历

上海人工智能实验室	研究实习生, 2022–至今
大语言模型安全蒸馏、推理时对齐与高效解码	

Subliminal Learning as Trait-Direction Drift: A Mechanism and Targeted Control under SFT Distillation	第一作者; 进行中的工作
---	--------------

- 独立负责选题、方法、实现、实验与论文写作; 提出 trait-direction drift 机制, 解释隐藏特质如何通过语义无关的蒸馏数据迁移至学生模型。
- 提出 probe-space corridor 定向抑制特质漂移, 将 malicious-response transfer 从 29.55% 降至 6.47%, 同时保持主任务性能。

Decoupled Contrastive Decoding via Expert-Aligned Drafting (DCD)	第一作者; 进行中的工作
--	--------------

- 独立负责选题、方法、SGLang 实现、实验与论文写作; 提出 DCD, 以 expert-aligned drafter 替代串行 amateur proposal, 并保持原始 contrastive decoding 的目标分布。
- 在 HumanEval、GSM8K、MMLU 与 CNN/DM 的三组 8B 配置上获得 1.65–1.95 $\times$ 平均加速, 70B 扩展达到约 2 $\times$ 加速。

Inference-Time Language Model Alignment via Integrated Value Guidance (IVG)	共同第一作者 (第一署名); EMNLP 2024 Findings
---	------------------------------------

- 负责选题、方法、代码、实验与论文写作; 提出 IVG, 结合 token-level 隐式价值与 chunk-level 搜索, 在无需微调目标大模型的情况下对齐生成。
- 在 AlpacaEval 2.0 上将 Mistral-7B / Mixtral-8 $\times$ 7B 的 LC win rate 从 19.51% / 25.58% 提升至 26.51% / 33.75%; 后续扩展为 SafeWork-R1 的推理时对齐模块, 将安全得分从 77.1 提升至 93.8。[代码]

Weak-to-Strong Search: Align Large Language Models via Searching over Small Language Models	第二作者 / Core Contributor; NeurIPS 2024
---	---------------------------------------

- 深度参与构思、方法、代码、实验与论文写作; 以小模型偏好差构造 dense reward/value, 通过 Chunk-level Beam Search 引导冻结大模型, 支持跨词表与黑盒模型。
- 使用 LC win rate 约 9.5% 的 7B 弱模型, 将 Llama-3-70B-Instruct 从 34.42% 提升至 39.09%; 对黑盒 GPT-3.5-Turbo-Instruct 从 16.00% 提升至 20.07%。[代码]

字节跳动 AI Lab	研究实习生, 2020.09–2021.06
神经符号学习、程序合成与数值推理	

A Neural-Symbolic Approach to Natural Language Understanding	第一作者; EMNLP 2022 Findings
--	---------------------------

- 负责选题、方法、实现、数据、实验与论文写作; 提出 Neural-Symbolic Processor, 以 Mixture-of-Experts 结合神经预测与程序生成 / 符号执行。
- 构建 32,011 条 DROP 程序监督数据和 722 条 AWPNLI E/C-Program 标注; 在 DROP 上达到 80.81 EM / 84.01 F1, 复杂乘除与平均运算 F1 相对 neural baseline 提升 56.42, AWPNLI accuracy 达 92.24%。[代码]

其他代表性论文

Native Reasoning Models: Training Language Models to Reason on Unverifiable Data	ICLR 2026 Poster; 第二作者
Adaptive Prompt Optimization for Open-Ended Tasks: Uncertainty Preference as a Secondary Signal	ACL 2026 Findings; 第二作者
Emergent Response Planning in LLMs	ICML 2025 Poster; 第三作者

技能

编程与框架: Python, PyTorch, Hugging Face Transformers, SGLang 语言: 英语 CET-6
核心技术: 模型蒸馏与 SFT, DPO, reward/value modeling, speculative/contrastive decoding, 搜索式生成